



Case completo de Engenharia de Dados em português: ingestão event-driven com Databricks Auto Loader, arquitetura medalhão Raw → Bronze → Silver → Gold, governança no Unity Catalog e dashboard AI/BI.

Tecnologias Utilizadas



Visão Geral da Arquitetura



Camadas Medalhão

Raw (Landing)

- Armazenamento em `abfss://marathon-data@<storage>.dfs.core.windows.net/raw/`
- Subpastas por fonte: `raw/berlin/` , `raw/chicago/` , `raw/london/` , `raw/nyc/` , `raw/metadata/`
- Sem transformação; formato original dos CSVs
- JSONs brutos da API Open-Meteo em `raw/weather_api/`

Bronze

- Ingestão via **Databricks Auto Loader** (`cloudFiles`) — uma stream por subpasta
- Checkpoint e schema inferido por fonte
- Deduplicação por `row_hash` + `source` + `year` via Delta `MERGE`
- Tabelas externas: `bronze.berlin` , `bronze.chicago` , `bronze.london` , `bronze.nyc`


Silver

- Normalização de schema, padronização de nomes e tipos
- Integração das quatro fontes em `silver.marathons`
- Mascaramento de dados sensíveis (nomes e identificadores via SHA-256) — orientação LGPD
- Validação de qualidade e registro em `monitoring.data_quality_log`

Gold


- Agregações prontas para análise e dashboard
- Tabelas: `gold.kpi_summary` , `gold.top_countries` , `gold.weather_impact` , `gold.athletes_by_country` , etc.
- Enriquecimento climático via Open-Meteo em `gold.weather_impact`

Fluxo de Ingestão Event-Driven



O **Auto Loader** processa apenas arquivos ainda não vistos (checkpoint), enquanto o **MERGE** do Delta Lake garante idempotência: reexecutar o pipeline não gera duplicatas.

Pipeline Completo



Governança e Segurança

Aspecto	Implementação
Catálogo	Unity Catalog (<code>marathon</code> / <code>marathon_prod</code>)

Acesso ao ADLS	Azure Access Connector + Managed Identity + RBAC
Autenticação local	<code>az login</code> (Microsoft Entra ID)
Autenticação CI	GitHub OIDC federado → Azure
Segredos	Nenhuma chave estática; Databricks secrets guardam apenas configuração
LGPD	Hash SHA-256 de nomes/identificadores na Silver
Observabilidade	<code>monitoring.data_quality_log</code> com row counts, % nulos, schema drift e tempo de execução
Lineage	Capturado automaticamente pelo Unity Catalog

Repositório e Deploy

O deploy é feito em um comando:

```
python scripts/setup_all.py
```

Para CI/CD, o workflow `.github/workflows/release-deploy.yml` provisiona a infraestrutura, sobe os dados, implanta notebooks, cria o workflow e publica o dashboard.
